

ANTE EL SEMÁFORO: LA ESTADÍSTICA DETRÁS DE LA **IMPACIENCIA**

- Fase nacional de sondeos y experimentos -

Institución educativa

Col·legi Mare de Déu dels Àngels

Autores

Anna Wilshusen, Jana Díaz,

Joan Chordà, Laia Carreño

Profesor

Rubèn Salvador



ÍNDICE

1. Introducción	3
2. Hipótesis	3
2. 1. Hipótesis General	3
2. 2. Hipótesis específicas	3
3. Objetivos	3
3. 1. Objetivo principal	3
3. 2. Objetivos específicos	3
4. Metodología	4
4. 1. Datos	4
4. 2. Variables	4
4. 3. Muestra	4
4. 4. Cálculos estadísticos, procedimientos y gráficos	5
4.4.1. Cálculo de proporciones	5
4.4.2. Tablas de contingencia	5
4.4.3. Test de Chi-cuadrado	5
4.4.4. Modelo de regresión logística	6
4.4.5. Gráficos	8
5. Análisis de resultados	8
5. 1. Observaciones generales	8
5. 2. Estudio de los casos atípicos	8
5. 3. Gráficos de las proporciones	9
5. 4. Test de Chi-cuadrado	11
5. 5. Regresión logística	12
6. Conclusiones	13
6. 1. Propuestas de mejora	14
7. Agradecimientos	14
8. Bibliografía	15
 ANEXO	 16
1. Tablas de contingencia y proporciones	16
2. Test de Chi-cuadrado	16
3. Código de la regresión logística	17

1. Introducción

El crecimiento de los núcleos urbanos ha evolucionado de forma paralela a la organización del tránsito. A lo largo de la historia, el aumento de vehículos y peatones ha hecho necesarias nuevas normas para proteger a los ciudadanos. En este contexto, en el año 1868 se instaló el primer semáforo en Londres. Esta innovación inició un sistema que 158 años más tarde sigue salvando vidas a diario.

Hoy en día, los semáforos modernos se regulan mediante estudios estadísticos que permiten ajustar su temporización. Pero, a pesar de las regulaciones y cálculos, muchos peatones no actúan como se espera. En algunos casos, el problema puede ser un diseño urbano poco adecuado; en otros, las conductas de riesgo de los propios peatones. Así, el respeto a los semáforos no depende solo de cálculos estadísticos, sino del comportamiento humano. Por este motivo existen entidades dedicadas a la seguridad vial.

La Dirección General de Tránsito (DGT) es el organismo responsable de la seguridad vial en España, entendida como el conjunto de normas y medidas destinadas a prevenir accidentes y proteger a los usuarios de la vía pública. Según esta institución, cruzar en rojo se considera una infracción grave y puede comportar multas de hasta 200 €. Aun así, es una norma que no se suele respetar.

Según el Ministerio de Interior, en 2024, 206 de las 488 personas muertas en vías urbanas en España eran peatones (42%). A pesar de una disminución respecto al año anterior, continúan siendo el colectivo con más mortalidad en ciudades.

En este contexto, analizar el comportamiento de los peatones delante de los semáforos se vuelve especialmente relevante. El cruce en rojo no es una conducta puntual, sino que puede tener consecuencias graves para la seguridad de los peatones. Por este motivo, esta investigación estudiará el comportamiento de los peatones mediante observaciones, cálculos, gráficos y su análisis.

2. Hipótesis

2.1. Hipótesis general

Partiendo del objetivo de analizar el comportamiento de los peatones, se plantea la siguiente hipótesis: la decisión de cruzar un paso de peatones en rojo está condicionada por diferentes factores: la duración del semáforo, las características de la calle, el momento del día o el hecho de cruzar acompañado o en grupo pueden incentivar o frenar esta acción y, por tanto, condicionar la probabilidad de cruzar en rojo.

2.2. Hipótesis específicas

Para concretar la hipótesis general, se formulan las siguientes hipótesis específicas:

1. El porcentaje de cruces en rojo en hora valle es significativamente mayor que en hora punta.
2. Al aumentar el número de carriles, se reduce proporcionalmente el porcentaje de cruces en rojo.
3. El porcentaje de peatones que van solos y cruzan en rojo es mayor que el de grupos o parejas.
4. La duración del semáforo es directamente proporcional a los cruces en rojo en los últimos 10 s.

3. Objetivos

3.1. Objetivo principal

El objetivo principal es analizar los factores asociados al hecho de cruzar en rojo, considerando las condiciones del semáforo y la calle, así como el tamaño y tipo de grupo.

3.2. Objetivos específicos

A partir del objetivo principal, es posible determinar objetivos específicos orientados a la observación parcial de diferentes aspectos influyentes en el estudio:

1. Comparar la frecuencia de cruces entre hora punta y hora valle.
2. Analizar si se cruza menos en calles de doble sentido, teniendo en cuenta el número de carriles.
3. Estudiar la relación entre ir solo o acompañado y la probabilidad de cruzar.
4. Evaluar si una mayor duración del rojo aumenta los cruces en los últimos 10 s.
5. Identificar patrones comunes en los casos atípicos.

4. Metodología

Este estudio analiza el comportamiento de personas que cruzan pasos de peatones en cuatro calles de La Sagrera, escogidas por sus diferencias en el número de carriles, de sentidos de circulación y la duración del semáforo en rojo para peatones. Se registran las características del cruce: el momento, si el peatón cruza solo o en grupo, el tamaño del grupo, si lo hace en rojo o en verde y si se realiza en hora punta o valle. En casos atípicos, se registran factores como la dinámica del grupo, la edad aproximada o el género. Aunque estas variables son subjetivas, permiten identificar posibles correlaciones e interpretar mejor los resultados.

4.1. Datos

El trabajo se basa en un estudio observacional cuantitativo. Los datos se recogen observando el comportamiento de los peatones ante los cuatro semáforos y registrándolos en hojas de cálculo. Primero se anotan las características de la calle y, durante el sondeo, las características del cruce junto con las particularidades de los valores atípicos. Al tratarse de un estudio observacional, no se interviene en la conducta de los peatones; los datos se registran objetivamente, salvo en los casos atípicos.

4.2. Variables

La variable principal es el tipo de cruce, una variable cualitativa dicotómica con dos valores: cruce en rojo o en verde. Se ha elegido porque es observable y cuantificable. Además, permite analizar los factores que pueden estar relacionados con ella mediante comparaciones y cálculos estadísticos.

El tamaño del grupo constituye una variable cuantitativa discreta que clasifica a los peatones en individuos, parejas o grupos mayores. Por otro lado, se pretende analizar la posible relación entre ir acompañado y la decisión de cruzar.

El número de carriles y el sentido de circulación son variables categóricas que describen la calle. También se analiza la duración del rojo peatonal, una variable cuantitativa continua que se cree que puede estar asociada con la probabilidad de cruzar en rojo. También es necesario analizar si una calle ancha, de doble sentido o con un semáforo más largo se asocia a una mayor proporción de cruces en rojo.

El momento del cruce en rojo, dividido en tres intervalos (primeros 10 s, intervalo central, últimos 10 s), se selecciona como variable cuantitativa continua, medida con cronómetro, para analizar patrones por etapas.

4.3. Muestra

La población del estudio está formada por los peatones que cruzan por los semáforos estudiados en el barrio de la Sagrera, sin exclusiones, para hacer la muestra lo más representativa posible. La muestra analizada corresponde a los peatones observados en dos franjas horarias: hora punta y hora valle en cada calle, dedicando un total de dos horas de observación por vía.

A continuación se muestra una tabla con las descripciones correspondientes por cada vía seleccionada. En ella es posible ver toda la información asociada a las variables seleccionadas, así como otros detalles particulares en cada caso. Los puntos cercanos que se mencionan se sitúan a menos de 100 metros.

Calle	Características	Calle	Características
Gran de la Sagrera - Martí Molins	-Número de carriles: 2 -Dirección: unidireccional -Duración del rojo: 55 s -Duración del verde: 45 s -Observaciones: cercano a una escuela, zona residencial con tráfico moderado.	Garcilaso - Gran de la Sagrera	-Número de carriles: 2 + carril bici -Dirección: bidireccional -Duración del rojo: 55 s -Duración del verde: 44 s -Observaciones: escuela, estación de metro y tren cercanos, tráfico intenso en hora punta.
Clara Zetkin - Gran de la Sagrera	-Número de carriles: 1 -Dirección: unidireccional -Duración del rojo: 55 s -Duración del verde: 45 s -Observaciones: cercano a una escuela, zona residencial con tráfico moderado.	Meridiana - Fabra i Puig	-Número de carriles: 6 -Dirección: bidireccional -Duración del rojo: 60 s -Duración del verde: 50 s -Observaciones: estación de metro y tren cerca, tráfico intenso en hora punta.

Tabla 1. Características de las calles y semáforos estudiados. Fuente: propia (2026)

4. 4. Cálculos estadísticos, procedimientos y gráficos

Para analizar la relación entre la variable dependiente y las independientes, se realizan pruebas estadísticas para cuantificar patrones, teniendo en cuenta las variables estudiadas y el objetivo del análisis.

4.4.1. Cálculo de proporciones

Se calculan las proporciones de cruces en rojo por calle y variable, expresadas en porcentajes para identificar tendencias. Se usa la siguiente fórmula, donde $n_{\text{categoria}}$ representa los casos de cada categoría y n_{total} el total de datos observados.

$$p = \frac{n_{\text{categoria}}}{n_{\text{total}}}$$

4.4.2. Tablas de contingencia

Estas son tablas de doble entrada que organizan la frecuencia conjunta de dos variables categóricas y permiten calcular proporciones para identificar cómo varían los datos según cada situación.

Se elaboran tres tablas para organizar los datos y analizar la relación entre variables. La primera recoge los cruces en verde y rojo según franja horaria y calle; la segunda muestra el tamaño del grupo en los cruces en rojo; y la tercera los distribuye según el momento del ciclo del semáforo.

4.4.3. Test de Chi-cuadrado

Después de organizar las tablas, se aplica el test de Chi-cuadrado (χ^2), que permite analizar si existe una relación entre dos variables categóricas: el cruce y el resultado del semáforo (rojo/verde). Su objetivo es determinar si el comportamiento observado es similar en todos los cruces o si, por el contrario, depende de la ubicación; es decir, si las diferencias encontradas pueden explicarse por el azar o si indican una relación real entre las variables. Para tratar este análisis, se definen las siguientes hipótesis:

- Hipótesis nula (H_0): no existe relación entre el cruce y el resultado; la proporción de rojos es igual en todos los cruces. Sirve como referencia para calcular los valores esperados y el p -valor.
- Hipótesis alternativa (H_1): si existe relación entre el cruce y el resultado; al menos un cruce presenta una proporción diferente. Se asume si los datos no encajan con la H_0 .

Grado de libertad

El cálculo del grado de libertad (gl) indica cuántos valores de la tabla de los observados (tabla 9 del anexo) pueden variar independientemente según las restricciones impuestas por los totales de filas y columnas. Este valor es esencial para determinar cuántas celdas se deben usar en el cálculo del p -valor. Se calcula con la siguiente fórmula:

$$gl = (filas - 1)(columnas - 1)$$

Cálculo del estadístico χ^2

El test de Chi-cuadrado compara los datos observados con valores teóricos, llamados valores esperados. Estos son aquellos valores que habría si no existiera relación entre el cruce y el resultado del semáforo. Se calculan mediante la siguiente fórmula, donde E representa dichos valores:

$$E = \frac{(\text{total fila}) \times (\text{total columna})}{\text{total general}}$$

La diferencia entre valores observados y esperados se mide mediante el estadístico χ^2 , donde O representa los valores observados y E los valores esperados, cuya fórmula es:

$$\chi^2 = \sum \frac{(O-E)^2}{E}$$

La operación indica la diferencia entre los valores observados y los esperados bajo la hipótesis nula. Si son parecidos, χ^2 es pequeño; si difieren mucho, χ^2 es alto y sugiere una posible relación entre variables. Además, se expresan los resultados en una tabla para analizar las contribuciones individuales de cada vía.

El valor del estadístico χ^2 no se interpreta por sí solo, sino que se compara con una curva teórica llamada distribución Chi-cuadrado (χ^2), para obtener el p -valor. Esta distribución indica qué valores de χ^2 serían normales si no hubiera relación entre las variables y el experimento se repitiera en las mismas condiciones.

Cálculo del p -valor

El p -valor se obtiene a partir de la distribución χ^2 y representa la probabilidad de obtener un valor igual o mayor que el observado si la hipótesis nula fuera cierta. Por tanto, indica si el resultado es habitual o raro bajo H_0 : un p -valor alto es compatible con H_0 , mientras que un p -valor bajo aporta evidencia contra ella.

$$p = P(\chi^2 \geq \chi^2_{\text{observado}})$$

El p -valor se calcula como una integral de la función de densidad de la distribución χ^2 ; es decir, como el área de la curva χ^2 que queda a la derecha del valor observado. En esta expresión, $f(x; g_l)$ es la función de densidad de la distribución χ^2 con sus correspondientes grados de libertad, y Γ es la función gamma:

$$p = \int_{\chi^2_{\text{observado}}}^{\infty} f(x; g_l) dx$$

$$f(x; g_l) = \frac{1}{2^{g_l/2} \Gamma(g_l/2)} x^{g_l/2-1} e^{-x/2}$$

En la práctica, esta integral no se calcula manualmente, sino que se utilizan tablas estadísticas y software como *Excel*, *R* o *Python*.

Nivel de significancia

Por último, para tomar la decisión, se establece un nivel de significancia, que representa el umbral a partir del cual un resultado se considera lo bastante improbable como para rechazar la hipótesis nula. En este trabajo, se usa $\alpha = 0,05$, lo que supone un 5% de riesgo de rechazar H_0 siendo cierta. La decisión se toma comparando el p -valor con α : si el p -valor es menor que α , se rechaza H_0 ; si es igual o mayor, no se rechaza H_0 .

4.4.4. Modelo de regresión logística

Por otro lado, se desarrolla un modelo de regresión logística en *Python*, que se ejecuta en *Google Colab*. Este modelo analiza la relación entre diversas variables independientes y una variable de respuesta dicotómica, que toma el valor 1 cuando el peatón cruza en rojo y el valor 0 cuando no cruza en rojo.

Funcionamiento del modelo

A diferencia de la regresión lineal, que puede dar valores continuos no acotados, este modelo permite interpretar directamente el resultado como una probabilidad. La regresión logística utiliza la función sigmoide $g(z)$ para transformar un valor numérico en una probabilidad comprendida entre 0 y 1. En este modelo, dicho valor corresponde a $w \cdot x + b$, por lo que:

$$g(z) = \frac{1}{1+e^{-z}}$$

$$P(\text{cruzar}=1) = f_{w,b}(x) = \frac{1}{1+e^{-(w \cdot x + b)}}$$

donde x representa las variables del modelo, w los pesos asociados a cada una (positivos si aumentan la probabilidad de cruzar en rojo, y negativos si la reduce), b el término constante o intercepto que refleja la tendencia general del modelo, y $f_{w,b}(x)$ la probabilidad de que el peatón cruce en rojo.

En lugar de trabajar directamente con las variables por separado, se construye una combinación lineal que posteriormente se transforma mediante la función sigmoide para obtener la probabilidad de cruzar en rojo:

$$z = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

Variables del modelo

Las variables que se utilizan son:

- Cruza: 1 si el peatón cruza en rojo, 0 si no cruza en rojo.
- Hora_Punta: 1 si es hora punta, 0 si es hora valle.
- Carriles: número de carriles de la calle.
- Bidireccional: 1 si la calle es de doble sentido, 0 si es de sentido único.
- Duracion_Sem: duración de la fase roja del semáforo, en segundos.
- Fase_Final: 1 si el peatón cruza en rojo durante los últimos 10 s, 0 si cruza antes.
- Grupo: 1 si el peatón va en grupo, 0 si va solo.
- Tamano_Grupo: 1, 2 o 3, donde 3 representa grupos de 3 o más personas.

Entrenamiento del modelo

El objetivo del modelo es encontrar los valores de w y b que mejor se ajusten a los datos mediante:

1. Función de pérdida: mide el error entre la predicción del modelo y el valor real para cada ejemplo, donde y es la variable respuesta y toma el valor 1 si el peatón cruza en rojo y 0 si no cruza en rojo.

$$L(w, b) = -y \log(f_{w,b}(x)) - (1 - y) \log(1 - f_{w,b}(x))$$

2. Función de coste: representa la media del error para todos los ejemplos del conjunto de datos.

$$J(w, b) = \frac{1}{m} \sum_{i=1}^m L(w, b)$$

3. Optimización: esta función se minimiza utilizando el método de descenso del gradiente, que ajusta iterativamente los valores de w y b para reducir el error del modelo.

Validación del modelo

El conjunto de datos se divide aleatoriamente en un 80% de entrenamiento, para aprender los valores de w y b , y un 20% de validación, para comprobar el funcionamiento del modelo con datos que no ha visto.

Objetivos

El modelo tiene como objetivo ser predictivo, ya que busca anticipar si un peatón cruza en rojo, y explicativo, ya que pretende analizar qué factores influyen más. El código, entonces, busca:

- Obtener los valores de los parámetros w y b , y analizar la influencia de los factores a partir de w .
- Calcular, en los datos de validación, la probabilidad de cruzar en rojo y predecir, con un umbral de 0.5, si cada peatón cruza en rojo, para obtener la accuracy del modelo (el porcentaje de aciertos).

Además, el código visualiza los resultados mediante diferentes representaciones gráficas:

- Coeficientes del modelo: muestra el peso w asociado a cada variable y su importancia relativa.
- Distribución de probabilidades: indica si el modelo predice con seguridad o incertidumbre.
- Matriz de confusión: compara predicciones y valores reales, mediante TN (True Negatives), TP (True Positives), FP (False Positives) y FN (False Negatives).
- Curva ROC y AUC: analiza el rendimiento del modelo para todos los posibles umbrales.

Código

Para entender mejor el funcionamiento de la regresión logística, el modelo se desarrolla mediante una implementación manual, programando directamente las expresiones matemáticas. Se utiliza *Python* y los datos se proporcionan mediante un archivo CSV, extraído de las tablas de contingencia, donde cada fila corresponde a un peatón y sus características.

El código importa las librerías necesarias y carga el archivo CSV, cuya estructura se revisa. También prepara el conjunto separando la variable respuesta, Cruza (y), del resto de variables explicativas (X). Los datos se dividen en un 80% de entrenamiento y un 20% de validación mediante `train_test_split`, manteniendo la proporción entre los valores de la variable respuesta con *stratify* (un parámetro).

Una vez preparados los datos, el código convierte X e y en matrices numéricas con `.values.astype(float)` para poder operar con ellas directamente. Después, define la función sigmoide, la función de coste (donde añade `eps` para evitar calcular $\log(0)$) y el cálculo de los gradientes. Finalmente, mediante el método del descenso del gradiente, obtiene los valores finales de w y b : en cada iteración calcula la diferencia entre la predicción y el valor real; para w , la combina con cada variable, y para b , calcula la media, actualizando ambos parámetros para reducir la función de coste. Después, se calcula el coste final como medida del error medio del modelo.

Con w y b , el código calcula $w \cdot X + b$ en los datos de validación y aplica la sigmoide para obtener la probabilidad. Después, usa una condición con umbral 0.5 para convertirla en predicción binaria. Luego, calcula la accuracy como la media de coincidencias entre y_pred e y_test , asignando 1 a cada acierto y 0 a cada error.

Después, organiza los coeficientes en un `DataFrame`, crea una columna con sus valores absolutos para calcular la importancia relativa y los ordena con `sort_values`. Para estudiar la distribución de probabilidades, ordena las probabilidades predichas con `np.sort` y las representa con `scatter`. Para la matriz

de confusión, cuenta TN, TP, FP y FN con condiciones lógicas, los coloca en una matriz 2x2 y la representa con imshow, escribiendo los valores en cada celda. Para la curva ROC, prueba distintos umbrales entre 0 y 1, calcula TPR (True Positive Rate) y FPR (False Positive Rate) en cada caso y representa la curva con plot; el AUC se obtiene como el área bajo esa curva.

$$(TPR = \frac{TP}{TP+FN}) \quad (FPR = \frac{FP}{FP+TN})$$

Finalmente, prueba un nuevo peatón en un DataFrame, calcula $w \cdot X + b$, aplica la sigmoide y predice.

4.4.5. Gráficos

Para facilitar la interpretación de los resultados, se elaboran gráficos adaptados a los tipos de variables estudiados. Estos permiten obtener una visión clara de los patrones de comportamiento de los peatones.

Se usa un diagrama de sectores que muestra la proporción total de cruces en verde y en rojo. También, se realiza un gráfico de barras apiladas, que permite comparar el volumen total de peatones en cada semáforo y distinguir visualmente cuántos cruzan en cada caso. En este gráfico, el eje de abscisas (X) incluye los semáforos analizados y el eje de ordenadas (Y) la frecuencia absoluta de peatones.

Se elaboran dos gráficos de barras agrupadas, uno para la hora punta y otro para la hora valle. Estos permiten comparar los porcentajes de cruces en rojo y en verde según el semáforo y la franja horaria. El eje X muestra el porcentaje de peatones y el eje Y los semáforos estudiados.

Se utiliza un gráfico de barras apiladas para mostrar en qué momento del ciclo del semáforo se producen los cruces en rojo: en los primeros 10 segundos, en el intervalo central o en los últimos 10 segundos. Esto permite comparar los patrones observados entre los semáforos y los horarios. El eje X indica el número de peatones y el eje Y los semáforos, diferenciando hora punta y hora valle.

Se elabora un gráfico de barras apiladas al 100% para representar los cruces en rojo según el tamaño del grupo (individual, parejas o grupos de 3+). Permite analizar si la compañía influye en el comportamiento de los peatones. En el eje X aparecen los semáforos y en el eje Y los porcentajes acumulados.

También se elabora un gráfico de barras apiladas que representa el momento preciso en el que se producen los cruces en rojo durante el ciclo del semáforo.

5. Análisis de resultados

5.1. Observaciones generales

El tamaño total de la muestra es de 2.346 peatones, repartidos en cada cruce de la siguiente forma:

- Calle Gran de la Sagrera - Calle Martí Molins: 314 peatones
- Calle Clara Zetkin - Calle Gran de la Sagrera: 297 peatones
- Calle Garcilaso - Calle Gran de la Sagrera: 1.074 peatones
- Avenida Meridiana - Paseo de Fabra i Puig: 661 peatones

5.2. Estudio de los casos atípicos

Calle Gran de la Sagrera y Calle de Clara Zetkin

En la mayoría de los casos, los peatones cruzan en rojo sin esperar, destacando aquellos que esperan al verde. Se estudian sus características aparentes y, pese a su posible subjetividad, se agrupan en:

- Pareja joven: 6 personas (3 parejas).
- Familias con niños menores de 9 años aproximadamente: 21 personas entre las familias.
- Mujeres de la tercera edad: 3 personas.

Calle Garcilaso y Avenida Meridiana

Contrariamente a los anteriores dos semáforos, en este se consideran atípicos aquellos individuos que cruzan en rojo, ya que la conducta mayoritaria es esperar al verde. Se agrupan en:

- Edades: menores de 20 años: 34 personas; entre 20 y 35 años: 35 personas; entre 35 y 60 años: 38 personas; mayores de 60 años: 1 persona.
- Familias pequeñas: 7 personas.
- Corredores: 4 personas.

En el caso de la Avenida Meridiana se detectan dos patrones clave:

- Peatones que cruzan justo al ponerse el semáforo en rojo: ya han iniciado el cruce cuando cambia la señal y aceleran para terminar de cruzar.
- Personas que hacen deporte: la cercanía a las pistas de Can Dragó explica que varios casos atípicos son corredores que cruzan justo al cambiar el semáforo, para mantener, quizá, el ritmo.

5. 3. Gráficos de las proporciones

Cruces en rojo y verde por semáforo




Figura 1. Cruces en rojo y verde por semáforo.
Fuente: propia (2026)




Figura 2. Cruces totales en rojo y verde.
Fuente: propia (2026)

Como se muestra en el diagrama de sectores, globalmente el 16,8% de los cruces se hacen en rojo. En **Gran de la Sagrera-Martí Molins**, los 126 cruces en rojo representan alrededor del 40% del total, una proporción significativamente superior, con un 23,3% por encima de la media. En **Clara Zetkin-Sagrera**, el incumplimiento es aún mayor: 150 cruces en rojo, equivalentes a un 50,5%, la cifra más alta de todas las intersecciones. En **Garcilaso-Sagrera**, pese a registrar el mayor número de peatones (1074), solo 97 cruzaron en rojo (9%), una proporción baja frente al resto. En **Meridiana-Fabra i Puig**, los 22 cruces en rojo suponen apenas un 3,3%, la proporción más baja.

Como muestra el análisis proporcional, el volumen de peatones parece influir en la proporción de cruces en rojo. En concreto, las calles con más cruces por hora presentan una menor proporción de infracciones, lo que sugiere que en ellas se respeta más el semáforo en rojo.

Cruces en verde y en rojo según el semáforo y el momento del día




Figura 3. Porcentaje de cruces en verde y rojo por semáforo (hora punta). Fuente: propia (2026)




Figura 4. Porcentaje de cruces en verde y rojo por semáforo (hora valle). Fuente: propia (2026)

En **Gran de la Sagrera-Martí Molins**, la proporción de cruces en rojo es mayor en hora punta (46,5%) que en hora valle (31%), lo que sugiere que un mayor flujo de peatones puede favorecer el incumplimiento. En **Clara Zetkin-Sagrera**, en hora punta, el 51,1% de los peatones cruza en rojo, mientras que en hora valle lo hace el 49,5%. En **Garcilaso-Sagrera**, los valores se mantienen muy estables: 8,5% en hora punta y 10,7% en hora valle, con barras prácticamente idénticas. Esto refleja un comportamiento constante en ambas franjas, sin variaciones relevantes. En **Meridiana-Fabra i Puig**, los porcentajes son muy bajos en ambas franjas (3,6% y 2,8%), reflejando un cumplimiento homogéneo.

En conjunto, los gráficos muestran que la relación entre franja horaria e infracciones varía según la intersección, pero no de forma consistente. Esto sugiere que la hora punta o valle no es un factor con mucho peso en el estudio.

Distribución de los cruces en rojo según el momento del cruce




Figura 5. Distribución de los cruces en rojo según el momento del cruce por semáforo. Fuente: propia (2026)

En **Gran de la Sagrera-Martí Molins**, la mayoría de infracciones se concentran en el tramo central del rojo (entre el 64% y el 77,5%), mientras que los primeros segundos apenas registran casos. En **Clara Zetkin-Sagrera** se observa un patrón similar: el intervalo central supera el 70% de los cruces tanto en hora punta como en hora valle, con valores bajos al inicio y moderados al final. En **Garcilaso-Sagrera**, la distribución es más equilibrada: alrededor del 46% de las infracciones se producen en el tramo central, mientras que el inicio y el final del rojo también tienen un peso relevante (entre el 18% y el 32%). Esto puede relacionarse con un entorno de más carriles y mayor tráfico. En cambio, **Meridiana-Fabra i Puig** presenta un patrón extremo, ya que el 100% de las infracciones se producen en los primeros 10 segundos del rojo, sin cruces posteriores.

En conjunto, el momento del cruce depende de las características del entorno: en calles más estrechas, las infracciones se concentran en el tramo central, mientras que en vías más amplias o con tráfico intenso aparecen distribuciones más variadas o incluso totalmente concentradas en un único momento del ciclo.

Distribución del tamaño del grupo en los cruces en rojo




Figura 6. Distribución del tamaño del grupo en los cruces en rojo por semáforo. Fuente: propia (2026)

En **Gran de la Sagrera-Martí Molins**, los cruces individuales alcanzan el 70% en hora valle, pero en hora punta bajan notablemente: las parejas suben al 49% y los grupos de tres o más al 15%. En **Clara Zetkin-Gran de la Sagrera**, la distribución es más equilibrada. En hora punta, los individuos representan el 40% y las parejas el 46,3%; en hora valle, los individuos bajan al 29,1% y los grupos aumentan hasta el 23,6%. En **Garcilaso-Sagrera**, los individuos son mayoría en hora punta (58%), pero en hora valle las parejas pasan a ser el grupo principal (50%). En **Meridiana-Fabra i Puig**, los valores son bajos y estables: entre 42% y 47% de individuos y 53%-57% de parejas, sin grupos grandes.

En conjunto, la importancia de cada tipo de grupo varía según la intersección: las parejas destacan en los puntos con más infracciones, mientras que los cruces individuales siguen siendo mayoritarios en zonas de mayor tráfico. Los grupos grandes solo tienen peso en algunas cruces y sobre todo en hora valle.

5. 4. Test de Chi-cuadrado

Grado de libertad

Aplicando la expresión a una tabla de contingencia de 4 filas y 2 columnas, se obtienen 3 grados de libertad. Este valor determina la distribución χ^2 de referencia utilizada para evaluar la significación estadística del contraste.

Cálculo del estadístico χ^2

Interpretación gráfica de los valores observados/esperados

La figura 7 compara los valores observados con los valores esperados bajo la hipótesis de independencia. Se observa que las diferencias no son pequeñas ni aleatorias, sino que siguen un patrón muy marcado. En las vías C1 y C2 se registran muchos más cruces en rojo de los que se esperarían si la ubicación no influyera en el comportamiento de los peatones. Por el contrario, en C3 y C4 sucede lo contrario: el número de cruces en rojo es considerablemente inferior al esperado. Por tanto, el gráfico sugiere que la distribución de cruces en rojo y verde depende de la vía analizada.




Figura 7. Comparación de valores observados y esperados de los semáforos (rojo/verde). Fuente: propia (2026)

Resultado del estadístico χ^2

El resultado del cálculo es $\chi^2 = 494,95$. Este valor indica que existe una diferencia global muy elevada entre los datos observados y los esperados bajo la hipótesis de independencia. Por ende, constituye una primera evidencia de que la vía se asocia con diferencias en el comportamiento de los peatones.

Tabla de contribuciones χ^2

La tabla 11 del anexo muestra que la vía C2 aporta casi la mitad del valor total del estadístico χ^2 (48,6 %), seguida de C1 (24,6 %), C4 (17,4 %) y C3 (9,4 %). Esto indica que las mayores diferencias entre los valores observados y esperados se concentran especialmente en C2 y C1, por lo que estas intersecciones son las principales responsables de la relación detectada.

Distribución de χ^2 e interpretación

La figura 8 representa la distribución χ^2 correspondiente a 3 grados de libertad e incorpora la posición del valor obtenido en el estudio ($\chi^2 = 494,95$).

Se observa que la mayor parte de los valores compatibles con la hipótesis nula se concentran muy cerca del origen de la distribución. Sin embargo, el valor obtenido se sitúa extremadamente alejado de esta región, apareciendo en la cola extrema de la curva. La distancia entre el valor observado y la zona central de la distribución es tan elevada que resulta muy improbable atribuirlo al azar.




Figura 8. Distribución χ^2 con valor observado (495) respecto a la densidad. Fuente: propia (2026)

Cálculo e interpretación del p -valor

El p -valor obtenido es prácticamente nulo ($p < 0,001$), muy inferior al nivel de significancia establecido ($\alpha = 0,05$). Esto indica que, si no hubiera relación entre las variables, sería extremadamente improbable observar diferencias tan grandes. Por tanto, se rechaza la hipótesis nula y se concluye que existe una relación estadísticamente significativa entre cruce y conducta peatonal.

Conclusión del test

El análisis muestra que existe una relación significativa entre el cruce analizado y el comportamiento de los peatones. Los distintos indicadores del test conducen a la misma conclusión: las diferencias entre los valores observados y esperados son muy elevadas, el estadístico χ^2 alcanza un valor de 494,95 y el p -valor obtenido es prácticamente nulo, muy inferior al nivel de significancia establecido.

Por tanto, se rechaza la hipótesis nula de independencia. Esto significa que las diferencias observadas entre cruces no pueden atribuirse al azar, sino que indican que las características de cada cruce se asocian con diferencias en la decisión de los peatones de cruzar en rojo o esperar.

5. 5. Regresión logística

Interpretación de coeficientes e intercepto




Figura 10. Coeficientes del modelo. Fuente: propia (2026)




Figura 11. Importancia relativa de los coeficientes del modelo. Fuente: propia (2026)

El modelo obtiene $b \approx 0,0031$. Como b es casi nulo, no indica una tendencia inicial clara a cruzar en rojo o no.

Respecto a los coeficientes w , mostrados en la figura 10, los de mayor valor absoluto, representados en la figura 11, son Bidireccional (-0,77), Carriles (-0,54) y Tamano_grupo (-0,39). Todos tienen efecto negativo: en calles bidireccionales, con más carriles o con grupos mayores, se reduce la probabilidad de cruzar en rojo, siendo la bidireccionalidad el factor más influyente. Fase_Final (+0,12) aumenta ligeramente esta probabilidad, mientras que Grupo (-0,11) la reduce un poco. Duracion_Sem (+0,02) y Hora_Punta (-0,02) no son factores relevantes; en el caso de la duración del semáforo, esto puede deberse a la poca diferencia entre los tiempos observados, de solo 5 s, aunque podría tener más relevancia con duraciones más variadas.

Evaluación del rendimiento del modelo

El modelo obtiene una accuracy de 0,8234 (82,34%), lo que indica un buen rendimiento global. Sin embargo, la matriz de confusión (figura 12) muestra que acierta sobre todo en los casos en que los peatones no cruzan: TN = 376, TP = 11, FP = 15 y FN = 68.

Esto indica que el modelo predice muy bien los casos de no cruce, pero tiene más dificultades para detectar a quienes sí cruzan. Por ende, es un modelo conservador, ya que tiende a predecir que el peatón no cruzará.

Aun así, el modelo identifica casos con mayor probabilidad de cruce, aunque el umbral de decisión de 0,5 hace que muchos no se clasifiquen como tales.




Figura 12. Matriz de confusión del modelo. Fuente: propia (2026)

Distribución de probabilidades // Curva ROC y AUC



Figura 13. Probabilidades predichas ordenadas del modelo. Fuente: propia (2026)




Figura 14. Curva ROC del sistema. Fuente: propia (2026)

La figura 13 muestra que el modelo tiende a asignar valores más cercanos a 0 que a 1. Esto confirma que está más seguro al predecir que no se cruza, mientras que muestra más incertidumbre en los casos de cruce. Los valores cercanos a 0,5 representan casos con comportamiento menos predecible.

Como muestra la figura 14, el modelo presenta una AUC $\approx 0,8365$, lo que indica que distingue bien entre peatones que cruzan en rojo y peatones que no. Sin embargo, al usar un umbral de 0,5, muchos casos con cierta probabilidad de cruce no llegan a clasificarse como positivos.

Ecuación de probabilidad de cruzar del modelo

Con los datos del modelo, la ecuación que estima la probabilidad de cruce, con una accuracy del 82,34%:

$$P(\text{cruzar}=1) = \frac{1}{1+e^{-z}}$$

donde $z = (-0,0168) \cdot \text{Hora_Punta} + (-0,5436) \cdot \text{Carriles} + (-0,7743) \cdot \text{Bidireccional} + (0,0176) \cdot \text{Duracion_Sem} + (0,1231) \cdot \text{Fase_Final} + (-0,1074) \cdot \text{Grupo} + (-0,3937) \cdot \text{Tamaño_Grupo} + 0,0031$

Predicción de un peatón

La predicción coincide con el ejemplo observado: el peatón va solo, ante una calle bidireccional de 4 carriles y un semáforo rojo de 55 s en una hora no punta, y no cruza, como predice el modelo (probabilidad de cruce en rojo: 0,12). Aun así, se recuerda que el modelo no es exacto y no siempre funcionará.

Conclusión del modelo

El modelo muestra buen rendimiento global, con una accuracy del 82,34% y una AUC de 0,8365. Sin embargo, tiende a predecir que los peatones no cruzan en rojo, ya que los datos están desequilibrados: hay muchos más casos de peatones que no cruzan en rojo que casos de cruce en rojo. Por ello, el modelo aprende mejor el patrón mayoritario y puede mantener una accuracy elevada, aunque identifica peor los cruces en rojo debido al desequilibrio de los datos y al uso de un umbral fijo de 0,5.

Pese a esta limitación predictiva, el modelo es útil desde el punto de vista explicativo: la bidireccionalidad, el número de carriles y el tamaño del grupo son las variables con mayor peso en el modelo.

6. Conclusiones

Este estudio observacional permite analizar el comportamiento de 2346 peatones en cuatro calles de La Sagrera y entender mejor qué hay detrás del hecho de cruzar en rojo. El resultado es bastante evidente: no es una conducta aleatoria, sino que está condicionada por diversos factores.

Esta idea se refleja en la hipótesis general que se confirma, aunque no por todos los factores estudiados. El test de Chi-cuadrado muestra diferencias significativas entre cruces. Además, la regresión logística explica que las variables con más peso son la bidireccionalidad, el número de carriles y el tamaño del grupo. Sin embargo, también concluye que ninguna variable actúa de forma determinante por sí sola, y otras, como la hora punta o la duración del semáforo, presentan una asociación muy débil. Por tanto, la decisión de cruzar en rojo responde a la combinación entre las características del entorno y del peatón.

En cuanto a las hipótesis específicas, no todas ellas se cumplen. La primera hipótesis, que preveía más cruces en rojo en hora valle, no se confirma: los datos varían según la intersección y no muestran un patrón común. Los gráficos comparativos entre hora punta y hora valle y la regresión logística indican que el momento del día no influye del mismo modo en todos los cruces, por lo que la franja horaria tiene menos peso que las características propias de cada calle. La segunda sí se corrobora, puesto que las calles con más carriles y bidireccionales presentan menos cruces en rojo, tal y como indica la regresión logística. Respecto al tamaño del grupo, no se confirma la idea de que ir solo aumenta los cruces en rojo, ya que en varios puntos destacan las parejas o grupos, sobre todo en los cruces con más infracciones. Finalmente, tampoco se cumple la última hipótesis, pues la duración del semáforo no resulta determinante y en algunas vías los cruces se concentran en el tramo central o en los primeros segundos, como se observa en la distribución por momentos del ciclo.

Además de las hipótesis planteadas, el análisis proporcional permite extraer otra observación: las calles con mayor volumen de peatones presentan una menor proporción de cruces en rojo.

En cuanto a los objetivos, se han alcanzado todos. Se ha podido analizar el comportamiento de los peatones, comparar los cruces según la hora, la calle y el tamaño del grupo, estudiar la influencia de las características del semáforo y detectar patrones en los casos atípicos. Además, los gráficos, las proporciones, el test de Chi-cuadrado y la regresión logística han permitido interpretar los resultados con suficiente profundidad. En este último caso, el modelo resulta especialmente útil desde un punto de vista explicativo, ya que permite identificar los factores con mayor peso, aunque su capacidad predictiva sea más limitada.

Respecto a los casos atípicos, la presencia de familias con niños, personas mayores o grupos más prudentes a menudo provoca que se espere al verde, incluso en cruces donde la mayoría cruza en rojo. En cambio, cuando la norma general es esperar, los pocos que cruzan suelen tener perfiles concretos, como corredores o personas que aprovechan los primeros segundos del cambio de semáforo. Esto indica que, más allá de los datos, intervienen factores sociales y de comportamiento.

En conjunto, el trabajo demuestra que cruzar en rojo no se debe a una única causa, sino a una mezcla de factores tanto individuales como del contexto. No obstante, al ser un estudio observacional, los resultados deben interpretarse como asociaciones entre variables y no como causalidades directas, siempre con el margen de incertidumbre propio de cualquier análisis estadístico.

Por este motivo, este estudio muestra que detrás de la planificación de un semáforo existe un factor difícil de medir: el comportamiento humano. Además, evidencia la utilidad del análisis estadístico en la planificación de los semáforos. Aunque las matemáticas buscan explicar el mundo con precisión, el humano siempre conserva una parte imprevisible. Precisamente esta es la esencia de la estadística aplicada: no eliminar la incertidumbre, sino medirla y utilizarla para comprender mejor lo que nos rodea.

6. 1. Propuestas de mejora

Tener en cuenta las limitaciones del estudio es clave para reducir el margen de incertidumbre propio de la estadística y mejorar la investigación. A continuación se presentan propuestas de mejora.

Aunque la muestra es amplia, sigue siendo limitada porque solo incluye cuatro cruces del mismo barrio. Ampliar la recogida de datos a otras zonas y más calles permitiría obtener resultados más representativos.

Algunas variables no se han podido medir de forma objetiva y se han basado en observación directa, lo que puede introducir sesgos. Se podrían incorporar métodos más precisos, como sistemas automatizados.

Además, algunas variables del entorno, como el número de carriles, la bidireccionalidad y la duración del semáforo, están ligadas a cada cruce concreto, de modo que sus efectos no pueden aislarse completamente. Por este motivo, los resultados del test de Chi-cuadrado y de la regresión logística deben interpretarse como evidencias de asociación dentro de la muestra observada.

En un futuro trabajo, el test de Chi-cuadrado podría complementarse con un mejor análisis de las contribuciones de cada celda. Esto permitiría comprender mejor por qué algunas vías presentan diferencias más marcadas que otras y ayudaría a dar contexto a los resultados estadísticos. Además, el análisis podría reforzarse con la comparación entre el valor obtenido del estadístico χ^2 con el valor crítico, que representa el número exacto a partir del cual se rechaza la hipótesis nula.

También sería recomendable tratar la variable Fase_Final en el modelo por separado, ya que solo tiene sentido en los cruces en rojo. Por tanto, puede estar parcialmente condicionada por la propia variable respuesta y no debería utilizarse como predictor cuando tratamos el modelo como predictivo.

El modelo de regresión logística funciona bien en general, pero tiene dificultades para predecir los cruces en rojo. Para mejorar su rendimiento, sería conveniente ajustar el umbral de clasificación, aplicar técnicas para equilibrar las clases y ampliar la muestra. También sería útil añadir variables como la intensidad del tráfico, el tiempo de espera, la presencia de vehículos, la meteorología o características de los peatones.

7. Agradecimientos

En primer lugar, queremos agradecer a nuestro tutor, Rubén Salvador, por su orientación en la elaboración del trabajo. También agradecemos a la Sociedad de Estadística e Investigación Operativa, organizadora del concurso Avatar, por promover la investigación y el interés por la estadística entre los jóvenes.

Asimismo, queremos destacar la ayuda de Rafa González Gouveia, cuyo tutorial de regresión logística fue clave para entender y replicar el modelo, así como la de Joan Gasull Jolis, cuyo vídeo sobre el test de Chi-cuadrado sirvió como guía durante el trabajo. También agradecemos a todas las personas que, indirectamente, aportaron datos al cruzar durante el sondeo.

Agradecemos igualmente a Alejandro Martínez y Judit Calpe su aparición como peatones extras en el vídeo, y a Txell Varela su ayuda en la grabación. Finalmente, reconocemos la influencia de The Beatles, especialmente de la canción *Here Comes the Sun* y la portada del álbum *Abbey Road*, que inspiraron la elección del tema. Por último, agradecemos a nuestro propio equipo su colaboración e implicación en el desarrollo del proyecto.

8. Bibliografía

Calculo.CC (2012). Variables estadísticas bidimensionales. 8 de marzo de 2026. Recuperado de: https://calculo.cc/temas/temas_estadistica/estadistica_bi/teoria/variable_bidi.html

ChReinvent (2021). Tablas de contingencia. 22 de febrero de 2026. Recuperado de: <https://www.chreinvent.com/recursos/tablas-de-contingencia>

Gobierno de España (2018). Hace 150 años, el primer semáforo. 20 de febrero de 2026. Recuperado de: <https://revista.dgt.es/es/multimedia/foto/2018/05021a-foto-num-244-Hace-150-anos-del-primer-semaforo.shtml>

González Gouvêa, R. (2022) Clase de regresión logística en Python: diabetes. 3 de abril de 2026. Recuperado de: <https://github.com/gonzalezgouveia/clases-youtube/tree/main/diabetes-logistic>

Herrera, H. (2024) Esta es la multa que puede recibir un peatón por cruzar con el semáforo en rojo. 21 de febrero de 2026. Recuperado de: https://www.larazon.es/motor/esta-multa-que-puede-recibir-peaton-cruzar-semaforo-rojo_2024082866cee32b797ae1000177b90a.html

IBM. ¿Qué es la regresión logística?. 22 de febrero de 2026. Recuperado de: <https://www.ibm.com/es-es/think/topics/logistic-regression>

Instituto Nacional de Estadística. Tipos de gráficos. 7 de marzo de 2026. Recuperado de: https://www.ine.es/explica/docs/pasos_tipos_graficos.pdf

JMP Statistical Discovery (2026). Prueba de independencia de ji cuadrado. 28 de marzo de 2026. Recuperado de: <https://www.jmp.com/es/statistics-knowledge-portal/chi-square-test/chi-square-test-of-independence>

Numiqo Team (2026). Logistic regression. 4 de abril de 2026. Recuperado de: <https://numiqo.com/tutorial/logistic-regression>

Solano González, N.D. (2022). ¿Por qué las personas no cruzan por donde los ingenieros quieren? Factores asociados a la decisión de incumplir el uso de puentes y cruces peatonales. 21 de febrero de 2026. Recuperado de: <https://repositorio.uniandes.edu.co/server/api/core/bitstreams/94b72147-5a66-4b8a-8147-cfabbad3a704/content>

UNED (2024). Pruebas Chi-cuadrado. 2 de abril de 2026. Recuperado de: <https://www.uned.es/universidad/inicio/estudios/formacion-permanente/cursos/experto-metodos-avanzados/programa/pruebas-chi-cuadrado.html>

ANEXO

1. Tablas de contingencia y proporciones

Se usará la siguiente notación: HP (hora punta), HV (hora valle), C1 (Gran de la Sagrera), C2 (Clara Zetkin), C3 (Garcilaso) y C4 (Meridiana). La fórmula según cada caso de estudio es la siguiente:

- (1) Cruces en rojo: $\frac{c. \text{rojo}}{c. \text{totales}} \times 100$
- (2) Cruces en rojo en h. valle y en h. punta: $\frac{c. \text{rojo} (* \text{franja horaria}^*)}{c. \text{totales} (* \text{franja horaria}^*)} \times 100$
- (3) Cruces en rojo según el intervalo y la franja horaria: $\frac{c. \text{rojo} (* \text{intervalo}^*, * \text{franja horaria}^*)}{c. \text{rojo} (* \text{franja horaria}^*)} \times 100$
- (4) Cruces en rojo según el grupo y la franja horaria: $\frac{c. \text{rojo} (* \text{grupo}^*, * \text{franja horaria}^*)}{c. \text{rojo} (* \text{franja horaria}^*)} \times 100$

	C1		C2		C3		C4	
	HP	HV	HP	HV	HP	HV	HP	HV
Rojo	86	40	95	55	69	28	15	7
Verde	99	89	91	56	743	234	399	240
Total	185	129	186	111	812	262	414	247

Tabla 2. Cruces por franja horaria. Fuente: propia (2026)

	C1		C2		C3		C4	
	HP	HV	HP	HV	HP	HV	HP	HV
(1)	40.1%	31%	51%	50%	8.5%	11%	3.6%	2.8%
(2)	47%	31%	51%	50%	8.5%	11%	3.6%	2.8%

Tabla 3. Proporciones por franja horaria. Fuente: propia (2026)

	C1		C2		C3		C4	
	HP	HV	HP	HV	HP	HV	HP	HV
10 s	2	6	7	6	15	5	15	7
-	31	55	69	41	32	12	0	0
-10 s	7	25	19	8	22	11	0	0

Tabla 4. Cruces por momento. Fuente: propia (2026)

(3)	C1		C2		C3		C4	
	HP	HV	HP	HV	HP	HV	HP	HV
10 s	7%	5%	7%	11%	22%	18%	100%	100%
-	64%	78%	73%	75%	46%	43%	0%	0%
-10 s	29%	17%	20%	14%	32%	39%	0%	0%

Tabla 5. Proporciones por momento. Fuente: propia (2026)

	C1		C2		C3		C4	
	HP	HV	HP	HV	HP	HV	HP	HV
1	31	28	38	16	40	11	7	3
2	42	12	44	26	16	14	8	4
3+	13	0	13	13	13	3	0	0

Tabla 6. Cruces por tamaño de grupo. Fuente: propia (2026)

(4)	C1		C2		C3		C4	
	HP	HV	HP	HV	HP	HV	HP	HV
1	36%	70%	40%	29%	58%	39%	47%	43%
2	49%	30%	46%	47%	23%	50%	53%	57%
3+	15%	0%	14%	24%	19%	11%	0%	0%

Tabla 7. Proporciones por tamaño de grupo. Fuente: propia (2026)

2. Test de Chi-cuadrado

Los cálculos se han realizado con *Google Sheets* para automatizar el proceso y obtener resultados exactos.

Cálculo	Proceso en <i>Google Sheets</i>
Valores esperados (con celdas aleatorias C9, E5 y E9)	$=(\$C9*E\$5)/\$E\$9 \rightarrow$ donde C9 = total fila; E5 = total columna; E9 = total general
χ^2	$=(O - E)^2 / E \rightarrow$ (celdas rojo/verde) $=SUM(columnas) \rightarrow$ resultado χ^2
P-valor	$=CHISQ.DIST.RT(\chi^2; \text{grados de libertad}) \rightarrow$ resultado p-valor
Representación gráfica de χ^2	Se usa la función densidad para visualizar la distribución y facilitar la interpretación del p-valor. 1. Eje x: $=SEQUENCE(1041;1;0;0,5)$ (valores hasta 520 aprox.) 2. Eje y: densidad de probabilidad $\rightarrow$ valor de 0 a 1 3. Curva: $=CHISQ.DIST(\chi^2, gl, FALSE) \rightarrow$ densidad para cada valor de la secuencia del eje x 4. Añadir constante del estadístico χ^2 en $x=494,95$

Tabla 8. Procedimiento estadístico en Sheets. Fuente: propia (2026)

Valores observados			
	Rojo	Verde	Total
C1	126	188	314
C2	150	147	297
C3	97	977	1074
C4	22	639	661
Total	395	1951	2346

Tabla 9. Valores observados. Fuente: propia (2026)

Valores esperados			
	Rojo	Verde	Total
C1	52,87	261,1	314
C2	50,01	247	297
C3	180,8	893,2	1074
C4	111,3	549,7	661
Total	395	1951	2346

Tabla 10. Valores esperados. Fuente: propia (2026)

χ^2			
	Rojo	Verde	Total
C1	101,16	20,48	121,64
C2	199,95	40,48	240,43
C3	38,86	7,87	46,73
C4	71,64	14,50	86,15
Total	411,61	83,34	494,95

Tabla 11. Aportes al χ^2 . Fuente: propia (2026)

3. Código de la regresión logística

Implementación, carga, inspección inicial y preparación de los datos

```
Python
csv_path = "datos_peatonos.csv"

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split

df = pd.read_csv(csv_path)

print("Dimensiones del dataset:", df.shape)
print("\nColumas:")
print(df.columns.tolist())
print("\nTipos de datos:")
print(df.dtypes)
print("\nValores nulos por columna:")
print(df.isnull().sum())

X = df.drop("Cruza", axis=1).copy()
y = df["Cruza"].copy()

X_train_df, X_val_df, y_train_s, y_val_s = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

print("Tamaño entrenamiento:", X_train_df.shape)
print("Tamaño validación:", X_val_df.shape)
```

Implementación manual de la regresión logística

```
Python
X_train = X_train_df.values.astype(float)
X_val = X_val_df.values.astype(float)
y_train = y_train_s.values.astype(float)
y_val = y_val_s.values.astype(float)
nombres_variables = X.columns.tolist()

def sigmoide(z):
    return 1 / (1 + np.exp(-z))

def calcular_coste(X, y, w, b):
    z = X @ w + b
    y_hat = sigmoide(z)
    eps = 1e-9
    return -np.mean(y * np.log(y_hat + eps) + (1 - y) * np.log(1 - y_hat + eps))

def calcular_gradientes(X, y, w, b):
    m = len(y)
    z = X @ w + b
    y_hat = sigmoide(z)
    error = y_hat - y

    dw = (X.T @ error) / m
    db = np.mean(error)
    return dw, db

def entrenar_regresion_logistica_manual(X, y, learning_rate=0.001, epochs=20000):
    w = np.zeros(X.shape[1])
    b = 0.0

    for i in range(epochs):
        dw, db = calcular_gradientes(X, y, w, b)
        w = w - learning_rate * dw
        b = b - learning_rate * db
    return w, b
```

Entrenamiento, predicciones y evaluación del modelo

```
Python
w_manual, b_manual = entrenar_regresion_logistica_manual(
    X_train, y_train, learning_rate=0.001, epochs=20000
)
print("w (manual):", w_manual)
print("b (manual):", b_manual)
print("Coste final:", calcular_coste(X_train, y_train, w_manual, b_manual))

probabilidad_cruzar = sigmoide(X_val @ w_manual + b_manual)
prediccion_manual = (probabilidad_cruzar >= 0.5).astype(int)
accuracy_manual = np.mean(prediccion_manual == y_val)
print("Accuracy del modelo manual:", round(accuracy_manual, 4))
```

Matriz de confusión

```
Python
tp = np.sum((prediccion_manual == 1) & (y_val == 1))
tn = np.sum((prediccion_manual == 0) & (y_val == 0))
fp = np.sum((prediccion_manual == 1) & (y_val == 0))
fn = np.sum((prediccion_manual == 0) & (y_val == 1))

matriz_confusion = np.array([[tn, fp], [fn, tp]])

print("TN:", tn)
print("TP:", tp)
print("FP:", fp)
print("FN:", fn)
print("\nMatriz de confusión:")
print(matriz_confusion)

plt.figure(figsize=(6, 5))
plt.imshow(matriz_confusion)
plt.xticks([0, 1], ["No cruza", "Cruza"])
plt.yticks([0, 1], ["No cruza", "Cruza"])
plt.xlabel("Predicción")
plt.ylabel("Valor real")
plt.title("Matriz de confusión")

for i in range(2):
    for j in range(2):
        plt.text(j, i, matriz_confusion[i, j], ha="center", va="center", fontsize=14)

plt.colorbar()
plt.tight_layout()
plt.show()
```

Interpretación de los coeficientes

```
Python
coef_df = pd.DataFrame({
    "Variable": nombres_variaciones,
    "Coeficiente": w_manual
}).sort_values("Coeficiente", ascending=False)
print(coef_df.to_string(index=False))

plt.figure(figsize=(9, 5))
plt.bar(coef_df["Variable"], coef_df["Coeficiente"])
plt.xticks(rotation=45, ha="right")
plt.xlabel("Variables")
plt.ylabel("Coeficiente")
plt.title("Coeficientes del modelo")
plt.axhline(0, linewidth=1)
plt.tight_layout()
plt.show()

coef_importancia_df = coef_df.copy()
coef_importancia_df["Importancia Absoluta"] = coef_importancia_df["Coeficiente"].abs()
coef_importancia_df = coef_importancia_df.sort_values("Importancia Absoluta",
    ascending=False)
print(coef_importancia_df.to_string(index=False))

plt.figure(figsize=(9, 5))
plt.bar(coef_importancia_df["Variable"], coef_importancia_df["Importancia Absoluta"])
plt.xticks(rotation=45, ha="right")
plt.xlabel("Variables")
plt.ylabel("Valor absoluto del coeficiente")
```

```
plt.title("Importancia relativa de los coeficientes")
plt.tight_layout()
plt.show()
```

Distribución probabilidades predichas

```
Python
plt.figure(figsize=(8, 5))
plt.scatter(range(len(probabilidad_cruzar)), np.sort(probabilidad_cruzar))
plt.xlabel("Peatones de validación ordenados")
plt.ylabel("Probabilidad predicha de cruzar en rojo")
plt.title("Probabilidades predichas ordenadas")
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```

Curva ROC y AUC manual

```
Python
def curva_roc_manual(y_real, y_prob):
    umbrales = np.linspace(0, 1, 101)
    lista_tpr = []
    lista_fpr = []

    for umbral in umbrales:
        y_pred_umbral = (y_prob >= umbral).astype(int)

        tp = np.sum((y_pred_umbral == 1) & (y_real == 1))
        tn = np.sum((y_pred_umbral == 0) & (y_real == 0))
        fp = np.sum((y_pred_umbral == 1) & (y_real == 0))
        fn = np.sum((y_pred_umbral == 0) & (y_real == 1))

        tpr = tp / (tp + fn) if (tp + fn) > 0 else 0
        fpr = fp / (fp + tn) if (fp + tn) > 0 else 0

        lista_tpr.append(tpr)
        lista_fpr.append(fpr)

    return umbrales, np.array(lista_tpr), np.array(lista_fpr)

umbrales, tpr, fpr = curva_roc_manual(y_val, probabilidad_cruzar)
orden = np.argsort(fpr)
fpr_ordenado = fpr[orden]
tpr_ordenado = tpr[orden]
auc_manual = np.trapezoid(tpr_ordenado, fpr_ordenado)

print("AUC aproximada:", round(auc_manual, 4))

plt.figure(figsize=(7, 7))
plt.plot(fpr_ordenado, tpr_ordenado, label=f"AUC ≈ {auc_manual:.4f}")
plt.plot([0, 1], [0, 1], linestyle="--")
plt.xlabel("False Positive Rate")
plt.ylabel("True Positive Rate")
plt.title("Curva ROC")
plt.legend()
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```

Predicción para un peatón nuevo

```
Python
nuevo_peaton = pd.DataFrame([
    {"Hora_Punta": 0,
     "Carriles": 4,
     "Bidireccional": 1,
     "Duracion_Sem": 55,
     "Fase_Final": 0,
     "Grupo": 0,
     "Tamano_Grupo": 0
    }])

x_nuevo = nuevo_peaton.values.astype(float)
prob_nuevo = sigmoide(x_nuevo @ w_manual + b_manual)[0]
pred_nuevo = int(prob_nuevo >= 0.5)

print("Probabilidad de cruzar en rojo:", round(prob_nuevo, 4))
print("Predicción final:", "Cruza en rojo" if pred_nuevo == 1 else "No cruza en rojo")
```